

Vision tridimensionnelle

Calibrage 1

Vincent Chapdelaine-Couture

Nicolas Martin

Sébastien Roy

Laboratoire Vision3D

Département d'informatique et de recherche opérationnelle



Automne 2023

- 1 Introduction
- 2 Calibrage avec objet 3D
- 3 Calibrage planaire
- 4 Calibrage par Rotation pure
- 5 Distortion radiale

Introduction

Un rappel du modèle de caméra perspective:

$$M = \underbrace{\begin{bmatrix} f & 0 & c_x \\ 0 & f & c_y \\ 0 & 0 & 1 \end{bmatrix}}_{\text{internes}} \underbrace{\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}}_{\text{projection}} \underbrace{\begin{bmatrix} r_{11} & r_{12} & r_{13} & 0 \\ r_{21} & r_{22} & r_{23} & 0 \\ r_{31} & r_{32} & r_{33} & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & t_x \\ 0 & 1 & 0 & t_y \\ 0 & 0 & 1 & t_z \\ 0 & 0 & 0 & 1 \end{bmatrix}}_{\text{externes}}$$

Calibrage et pose

Peut-on retrouver les paramètres de ce modèle à partir d'images?

Calibrage

Méthode permettant de retrouver les paramètres internes de la caméra :

- ▶ matrice K
- ▶ coefficients de distortion radiale

⇒ Une caméra calibrée est une caméra dont on connaît les **paramètres internes**

Estimation de pose

Méthode permettant de déterminer les **paramètres externes** :

- ▶ orientation : R
- ▶ position : t

Rappel: modèle de projection perspective : $M = KR[I|t]$

Calibrage

Méthode permettant de retrouver les paramètres internes de la caméra :

- ▶ matrice K
- ▶ coefficients de distortion radiale

⇒ Une caméra calibrée est une caméra dont on connaît les **paramètres internes**

Estimation de pose

Méthode permettant de déterminer les **paramètres externes** :

- ▶ orientation : R
- ▶ position : t

Rappel: modèle de projection perspective : $M = KR[I|t]$

De quelle information on dispose pour la calibration?

- ▶ Avec images d'un objet 3D connu
- ▶ Avec images d'un objets planaires (2D) connu
- ▶ Avec entités de l'image (points de fuite, angle entre les lignes)
- ▶ À partir de mouvements connus de la caméra

Grandes étapes

- ▶ Identifier les éléments (points, lignes, etc) dans les images
- ▶ Minimiser une fonction des paramètres et des entités projetées


De quelle information on dispose pour la calibration?

- ▶ Avec images d'un objet 3D connu
- ▶ Avec images d'un objets planaires (2D) connu
- ▶ Avec entités de l'image (points de fuite, angle entre les lignes)
- ▶ À partir de mouvements connus de la caméra

Grandes étapes

- ▶ Identifier les éléments (points, lignes, etc) dans les images
- ▶ Minimiser une fonction des paramètres et des entités projetées

Calibrage avec objet 3D



- ▶ Points 3D connus :
 - ▶ les coins d'un dodécaèdre
 - ▶ deux plans avec des damiers
- ▶ Points images détectés
 - ▶ pas toujours facile...
 - ▶ une détection à la main est souvent la solution la plus simple
- ▶ Est-ce que les points 3D peuvent être quelconques ?

Direct Linear Transform

On cherche M avec une méthode linéaire

p^i est l'image du point p_w^i telle que :

$$\tilde{p}^i \propto M \tilde{p}_w^i$$

- ▶ Donc : $\tilde{p}^i \times (M \tilde{p}_w^i) = 0$
- ▶ Chaque correspondance donne trois équations :
 - ▶ mais deux linéairement indépendantes
 - ▶ donc deux contraintes sur M
- ▶ M a 11 degrés de liberté : 12 entrées - 1 degré (facteur d'échelle)
- ▶ Il faut donc 5 1/2 correspondances pour retrouver M

DLT = Transformation Linéaire Directe

- ▶ On l'utilise pour résoudre les systèmes homogènes linéaires, comme : trouver x tel que $Ax = 0$ (soumis à la contrainte que $x \neq 0$)
- ▶ C'est la méthode qu'on a utilisé pour trouver les homographies dans le tp1
- ▶ Il suffit de ramener le problème original en : $\min ||Ax||$:
 - ▶ correspondances 2D-2D (homographie, modèle de caméra complet)
 - ▶ correspondances points-lignes (fondamentale : plus tard)
 - ▶ correspondances 3D-3D (alignement de nuage de points)
 - ▶ ...
- ▶ On résoud avec la SVD
- ▶ Cela minimise l'**erreur algébrique**

SVD = Décomposition en valeurs singulières

Pour toute matrice \mathbf{A} , $\mathbf{A}_{(n \times m)} = \mathbf{U}_{(n \times n)} \mathbf{\Sigma}_{(n \times m)} \mathbf{V}_{(m \times m)}^T$:

- ▶ \mathbf{U} et \mathbf{V} : matrices orthogonales ($\mathbf{U}\mathbf{U}^T = \mathbf{V}\mathbf{V}^T = \mathbf{I}$)

- ▶ $\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)_{(n \times m)} = \begin{bmatrix} \sigma_1 & 0 & 0 & \dots & & \\ 0 & \sigma_2 & 0 & \dots & & \\ \vdots & \vdots & \ddots & \dots & & \\ 0 & \dots & \dots & \sigma_r & & \\ & & \mathbf{0}^T & & & 0 \end{bmatrix}$ matrice diagonale

avec les valeurs singulières ordonnées ($\sigma_1 > \sigma_2 > \dots > \sigma_r > 0$)

- ▶ Décomposition qui n'est pas unique
- ▶ Reliée à la décomposition en valeurs/vecteurs propres de $\mathbf{A}^T \mathbf{A}$

Rang d'une matrice

maximum entre

- ▶ #lignes linéairement indépendantes
- ▶ #colonnes linéairement indépendantes

⇒ nombre de valeurs singulières non nulles = r

Nullspace de A

x tel que $Ax = 0$

⇒ colonnes de V associées aux valeurs singulières nulles

Pseudo-inverse

inverse d'une matrice non-carrée

⇒ $A^\dagger = V \Sigma^\dagger U^T$ avec $\Sigma^\dagger = \text{diag}(\sigma_1^{-1}, \sigma_2^{-1}, \dots, \sigma_r^{-1})_{(n \times m)}$

Moindres carrés linéaires

Que faire quand on a plus de points que le minimum requis?

n équations de la forme $\sum_{j=1}^m v_{ij}x_j = y_i$ avec $n \geq m$

⇒ résoudre $\sum_{i=1}^n \mathbf{v}_i^T \mathbf{x} = y_i$ avec $\mathbf{v}_i = (v_{i1}, v_{i2}, \dots, v_{im})^T$ et $\mathbf{x} = (x_1, x_2, \dots, x_m)^T$

⇒ résoudre $\mathbf{V}\mathbf{x} = \mathbf{y}$ avec $\mathbf{V} = \begin{bmatrix} \mathbf{v}_1 \\ \mathbf{v}_2 \\ \vdots \\ \mathbf{v}_n \end{bmatrix}$ et $\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$

⇒ solution : $\mathbf{x} = \mathbf{V}^\dagger \mathbf{y}$ (en utilisant la SVD)

Cas particulier : résoudre $\mathbf{V}\mathbf{x} = \mathbf{0}$

⇒ méthode DLT du tp1

Résoudre $\mathbf{Ax} = \mathbf{0}$ est équivalent à $\min \|\mathbf{Ax}\|$ sujet à $\|\mathbf{x}\| = 1$

► $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$

► on veut minimiser $\|\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$

► donc $\min \|\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$ (\mathbf{U} est orthonormale)

► soit $\mathbf{y} = \mathbf{V}^T\mathbf{x}$ alors on veut minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ avec la contrainte $\|\mathbf{x}\| = \|\mathbf{V}^T\mathbf{x}\| = \|\mathbf{y}\| = 1$ (\mathbf{V} est orthonormale)

► il suffit de choisir $\mathbf{y} = (0, 0, \dots, 0, 1)^T$ pour minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ (car $\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ avec $\sigma_1 > \sigma_2 > \dots > \sigma_r$)

► donc $\mathbf{x} = \mathbf{V}\mathbf{y}$ est la dernière colonne de \mathbf{V}

Ceci explique pourquoi on choisit toujours la dernière colonne de \mathbf{V} pour résoudre $\mathbf{Ax} = \mathbf{0}$ avec les méthodes DLT

Résoudre $\mathbf{Ax} = \mathbf{0}$ est équivalent à $\min \|\mathbf{Ax}\|$ sujet à $\|\mathbf{x}\| = 1$

- ▶ $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$
- ▶ on veut minimiser $\|\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$
- ▶ donc $\min \|\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$ (\mathbf{U} est orthonormale)
- ▶ soit $\mathbf{y} = \mathbf{V}^T\mathbf{x}$ alors on veut minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ avec la contrainte $\|\mathbf{x}\| = \|\mathbf{V}^T\mathbf{x}\| = \|\mathbf{y}\| = 1$ (\mathbf{V} est orthonormale)
- ▶ il suffit de choisir $\mathbf{y} = (0, 0, \dots, 0, 1)^T$ pour minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ (car $\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ avec $\sigma_1 > \sigma_2 > \dots > \sigma_r$)
- ▶ donc $\mathbf{x} = \mathbf{V}\mathbf{y}$ est la dernière colonne de \mathbf{V}

Ceci explique pourquoi on choisit toujours la dernière colonne de \mathbf{V} pour résoudre $\mathbf{Ax} = \mathbf{0}$ avec les méthodes DLT

Résoudre $Ax = 0$ est équivalent à $\min \|Ax\|$ sujet à $\|x\| = 1$

- ▶ $A = U\Sigma V^T$
- ▶ on veut minimiser $\|U\Sigma V^T x\|$
- ▶ donc $\min \|\Sigma V^T x\|$ (U est orthonormale)
- ▶ soit $y = V^T x$ alors on veut minimiser $\|\Sigma y\|$ avec la contrainte $\|x\| = \|V^T x\| = \|y\| = 1$ (V est orthonormale)
- ▶ il suffit de choisir $y = (0, 0, \dots, 0, 1)^T$ pour minimiser $\|\Sigma y\|$ (car $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ avec $\sigma_1 > \sigma_2 > \dots > \sigma_r$)
- ▶ donc $x = Vy$ est la dernière colonne de V

Ceci explique pourquoi on choisit toujours la dernière colonne de V pour résoudre $Ax = 0$ avec les méthodes DLT

Résoudre $\mathbf{A}\mathbf{x} = \mathbf{0}$ est équivalent à $\min \|\mathbf{A}\mathbf{x}\|$ sujet à $\|\mathbf{x}\| = 1$

- ▶ $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$
- ▶ on veut minimiser $\|\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$
- ▶ donc $\min \|\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$ (\mathbf{U} est orthonormale)
- ▶ soit $\mathbf{y} = \mathbf{V}^T\mathbf{x}$ alors on veut minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ avec la contrainte $\|\mathbf{x}\| = \|\mathbf{V}^T\mathbf{x}\| = \|\mathbf{y}\| = 1$ (\mathbf{V} est orthonormale)
- ▶ il suffit de choisir $\mathbf{y} = (0, 0, \dots, 0, 1)^T$ pour minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ (car $\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ avec $\sigma_1 > \sigma_2 > \dots > \sigma_r$)
- ▶ donc $\mathbf{x} = \mathbf{V}\mathbf{y}$ est la dernière colonne de \mathbf{V}

Ceci explique pourquoi on choisit toujours la dernière colonne de \mathbf{V} pour résoudre $\mathbf{A}\mathbf{x} = \mathbf{0}$ avec les méthodes DLT

Résoudre $\mathbf{Ax} = \mathbf{0}$ est équivalent à $\min \|\mathbf{Ax}\|$ sujet à $\|\mathbf{x}\| = 1$

- ▶ $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$
- ▶ on veut minimiser $\|\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$
- ▶ donc $\min \|\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$ (\mathbf{U} est orthonormale)
- ▶ soit $\mathbf{y} = \mathbf{V}^T\mathbf{x}$ alors on veut minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ avec la contrainte $\|\mathbf{x}\| = \|\mathbf{V}^T\mathbf{x}\| = \|\mathbf{y}\| = 1$ (\mathbf{V} est orthonormale)
- ▶ il suffit de choisir $\mathbf{y} = (0, 0, \dots, 0, 1)^T$ pour minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ (car $\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ avec $\sigma_1 > \sigma_2 > \dots > \sigma_r$)
- ▶ donc $\mathbf{x} = \mathbf{V}\mathbf{y}$ est la dernière colonne de \mathbf{V}

Ceci explique pourquoi on choisit toujours la dernière colonne de \mathbf{V} pour résoudre $\mathbf{Ax} = \mathbf{0}$ avec les méthodes DLT

Résoudre $\mathbf{Ax} = \mathbf{0}$ est équivalent à $\min \|\mathbf{Ax}\|$ sujet à $\|\mathbf{x}\| = 1$

- ▶ $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$
- ▶ on veut minimiser $\|\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$
- ▶ donc $\min \|\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$ (\mathbf{U} est orthonormale)
- ▶ soit $\mathbf{y} = \mathbf{V}^T\mathbf{x}$ alors on veut minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ avec la contrainte $\|\mathbf{x}\| = \|\mathbf{V}^T\mathbf{x}\| = \|\mathbf{y}\| = 1$ (\mathbf{V} est orthonormale)
- ▶ il suffit de choisir $\mathbf{y} = (0, 0, \dots, 0, 1)^T$ pour minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ (car $\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ avec $\sigma_1 > \sigma_2 > \dots > \sigma_r$)
- ▶ donc $\mathbf{x} = \mathbf{V}\mathbf{y}$ est la dernière colonne de \mathbf{V}

Ceci explique pourquoi on choisit toujours la dernière colonne de \mathbf{V} pour résoudre $\mathbf{Ax} = \mathbf{0}$ avec les méthodes DLT



Résoudre $\mathbf{Ax} = \mathbf{0}$ est équivalent à $\min \|\mathbf{Ax}\|$ sujet à $\|\mathbf{x}\| = 1$

- ▶ $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$
- ▶ on veut minimiser $\|\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$
- ▶ donc $\min \|\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}\|$ (\mathbf{U} est orthonormale)
- ▶ soit $\mathbf{y} = \mathbf{V}^T\mathbf{x}$ alors on veut minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ avec la contrainte $\|\mathbf{x}\| = \|\mathbf{V}^T\mathbf{x}\| = \|\mathbf{y}\| = 1$ (\mathbf{V} est orthonormale)
- ▶ il suffit de choisir $\mathbf{y} = (0, 0, \dots, 0, 1)^T$ pour minimiser $\|\mathbf{\Sigma}\mathbf{y}\|$ (car $\mathbf{\Sigma} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ avec $\sigma_1 > \sigma_2 > \dots > \sigma_r$)
- ▶ donc $\mathbf{x} = \mathbf{V}\mathbf{y}$ est la dernière colonne de \mathbf{V}

Ceci explique pourquoi on choisit toujours la dernière colonne de \mathbf{V} pour résoudre $\mathbf{Ax} = \mathbf{0}$ avec les méthodes DLT

Les points 3D et 2D

Avec un dodécahèdre :



Décomposition de M

Nous avons obtenu M .

Comment décomposer $M = KR[I|t]$ pour obtenir K , R , et t ?

Méthode indirecte:

$$\begin{aligned} M &= [H \mid m_4] \\ &= H [I \mid H^{-1}m_4] \\ &= KR [I \mid t] \end{aligned}$$

donc

- ▶ on retrouve la position t avec $H^{-1}m_4$
- ▶ on retrouve l'orientation R et les paramètres internes K avec $H = KR$
→ comment faire ??

Pour une matrice carrée $\mathbf{A}_{(n \times n)}$:

$$\mathbf{A} = \mathbf{Q}_{(n \times n)} \mathbf{R}_{(n \times n)}$$

avec

- ▶ \mathbf{Q} une matrice orthogonale : $\mathbf{Q}\mathbf{Q}^T = \mathbf{I}$
- ▶ \mathbf{R} une matrice triangulaire supérieure droite

Attention: Ici \mathbf{R} est une matrice triangulaire supérieure, alors que \mathbf{R} représente normalement une rotation ...

Pour une matrice carrée $\mathbf{A}_{(n \times n)}$:

$$\mathbf{A} = \mathbf{Q}_{(n \times n)} \mathbf{R}_{(n \times n)}$$

avec

- ▶ \mathbf{Q} une matrice orthogonale : $\mathbf{Q}\mathbf{Q}^T = \mathbf{I}$
- ▶ \mathbf{R} une matrice triangulaire supérieure droite

Attention: Ici \mathbf{R} est une matrice triangulaire supérieure, alors que \mathbf{R} représente normalement une rotation ...

Pour une matrice carrée $A_{(n \times n)}$:

$$A = R_{(n \times n)} Q_{(n \times n)}$$

avec

- ▶ R une matrice triangulaire supérieure droite
- ▶ Q une matrice orthogonale : $QQ^T = I$
- ▶ En Mathematica, il n'y a pas de fonction directe pour trouver la décomposition RQ, par contre elle est facile à trouver si on sait trouver une décomposition QR...
- ▶ C'est ce qu'il nous faut pour décomposer $H = KR$

Décomposition de M

Rappel : $\mathbf{K} = \begin{bmatrix} f & s & cx \\ 0 & \alpha f & cy \\ 0 & 0 & 1 \end{bmatrix}$

Méthode directe:

$$\mathbf{H} \propto \mathbf{K}\mathbf{R} = \rho \begin{bmatrix} f\mathbf{r}_1^\top + s\mathbf{r}_2^\top + cx\mathbf{r}_3^\top \\ \alpha f\mathbf{r}_2^\top + cy\mathbf{r}_3^\top \\ \mathbf{r}_3^\top \end{bmatrix}$$

donc:

- ▶ $\rho = \|\mathbf{h}_3\|$
- ▶ $\mathbf{r}_3 = \mathbf{h}_3/\rho$
- ▶ $cx = \mathbf{h}_1^\top \mathbf{h}_3/\rho^2$
- ▶ $cy = \mathbf{h}_2^\top \mathbf{h}_3/\rho^2$
- ▶ ...

Voir Forsyth-Ponce pour le reste

Idéalement, on minimise l'erreur géométrique...

Minimisation de l'erreur de reprojection

$$\sum_i \text{dist}^2(\mathbf{p}_i, \mathbf{M}\mathbf{p}_i)$$

Si on a des contraintes sur \mathbf{K} :

$$\sum_i \text{dist}^2(\mathbf{p}_i, \mathbf{K}\mathbf{R} \begin{bmatrix} \mathbf{I} & \mathbf{t} \end{bmatrix} \mathbf{p}_i)$$

⇒ requiert une méthode non-linéaire ...

Et si on utilisait un modèle de caméra affine?

$$\mathbf{p} - \begin{bmatrix} m_{11} & m_{12} & m_{13} & m_{14} \\ m_{21} & m_{22} & m_{23} & m_{24} \end{bmatrix} \tilde{\mathbf{p}}_w = \mathbf{p} - \begin{bmatrix} \mathbf{m}_1^\top \\ \mathbf{m}_2^\top \end{bmatrix} \tilde{\mathbf{p}}_w = \mathbf{0}$$

et le système est donc

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

$$\text{avec } \mathbf{A} = \begin{bmatrix} \tilde{\mathbf{p}}_w^{1\top} & \mathbf{0}^\top \\ \mathbf{0}^\top & \tilde{\mathbf{p}}_w^{1\top} \\ \vdots & \\ \tilde{\mathbf{p}}_w^{n\top} & \mathbf{0}^\top \\ \mathbf{0}^\top & \tilde{\mathbf{p}}_w^{n\top} \end{bmatrix}, \mathbf{x} = \begin{pmatrix} \mathbf{m}_1 \\ \mathbf{m}_2 \end{pmatrix} \text{ et } \mathbf{b} = \begin{bmatrix} \mathbf{p}^1 \\ \vdots \\ \mathbf{p}^n \end{bmatrix}$$

- ▶ On résout avec la pseudo-inverse ou SVD
- ▶ M n'est pas définie à un facteur d'échelle, donc exactement 8 degrés de libertés : seulement 4 correspondances suffisent
- ▶ Cela minimise l'erreur géométrique :

$$\|Ax\| = \sum_i^n (\mathbf{p}_i - M\tilde{\mathbf{p}}_w^i)^2 = \sum_i^n d_{\text{geom}}(\mathbf{p}_i, M\tilde{\mathbf{p}}_w^i)$$

Calibrage planaire

- ▶ Image d'un plan
- ▶ Géométrie euclidienne connue
- ▶ Paramètres internes calculés à partir de plusieurs vues
- ▶ Pose par rapport au plan pour chaque vue


Plan euclidien

On connaît un système d'axe euclidien dans ce plan. On connaît par exemple:

- ▶ l'angle entre les lignes
- ▶ la distance entre les points
- ▶ le fait que l'échiquier est constitué de “carrés”

Avec une grille de calibration:

- ▶ Trouver des points saillants
- ▶ Retrouver automatiquement la configuration des points (i.e. leur coordonnée)
 - ▶ Pas si difficile
 - ▶ En OpenCV :
`findChessboardCorners`



- Pour chaque damier retrouvé, on peut fixer l'origine du monde sur un des coins
- Sans pertes de généralité, on fixe le plan du damier en $Z = 0$
- Projection d'un plan en $Z = 0$

$$\mathbf{KR}[\mathbf{I}_{3 \times 3} | \mathbf{t}] \begin{pmatrix} X \\ Y \\ 0 \\ 1 \end{pmatrix} = \mathbf{KR} \begin{bmatrix} 1 & 0 & \\ 0 & 1 & t \\ 0 & 0 & \end{bmatrix} \begin{pmatrix} X \\ Y \\ 1 \end{pmatrix} = \mathbf{H} \begin{pmatrix} X \\ Y \\ 1 \end{pmatrix}$$

- Donc chaque damier fournit une homographie qui contient de l'information sur \mathbf{K}

Quelle contraintes peut-on trouver dans

$$\mathbf{H} = \mathbf{K} \mathbf{R} \begin{bmatrix} 1 & 0 \\ 0 & 1 & t \\ 0 & 0 \end{bmatrix} ?$$

On peut reformuler avec les colonnes de \mathbf{H} et \mathbf{R} :

$$\mathbf{H} = \begin{bmatrix} h_1 & h_2 & h_3 \end{bmatrix} = \mathbf{K} \begin{bmatrix} r_1 & r_2 & \mathbf{R}t \end{bmatrix}$$

donc clairement

$$h_1 = \mathbf{K} r_1 \text{ et } h_2 = \mathbf{K} r_2$$

et inversement

$$r_1 = \mathbf{K}^{-1} h_1 \text{ et } r_2 = \mathbf{K}^{-1} h_2$$

On sait que \mathbf{R} est orthogonale, donc $\mathbf{r}_1^\top \mathbf{r}_2 = 0$.

Puisque $\mathbf{r}_1 = \mathbf{K}^{-1}\mathbf{h}_1$ et $\mathbf{r}_2 = \mathbf{K}^{-1}\mathbf{h}_2$, on obtient la contrainte

$$\mathbf{h}_1 \mathbf{K}^{-\top} \mathbf{K}^{-1} \mathbf{h}_2 = 0$$

On voit que la contrainte est sur $\omega = \mathbf{K}^{-\top} \mathbf{K}^{-1}$, qu'on appelle l'image de la conique absolue.

On sait que \mathbf{R} est orthonormale, donc $\|\mathbf{r}_1\| = \|\mathbf{r}_2\|$.

Puisque $r_1 = \mathbf{K}^{-1}h_1$ et $r_2 = \mathbf{K}^{-1}h_2$, on obtient la contrainte

$$h_1 \mathbf{K}^{-\top} \mathbf{K}^{-1} h_1 = h_2 \mathbf{K}^{-\top} \mathbf{K}^{-1} h_2$$

Chaque homographie ajoute donc deux contraintes sur $\omega = \mathbf{K}^{-\top} \mathbf{K}^{-1}$. On va utiliser ces contraintes pour estimer ω , puis \mathbf{K} .

Essayons de trouver d'où vient ω , l'image de la conique absolue ...

Définition

Une conique est une courbe d'équation du second degré dans le plan

- ▶ Issu de l'intersection d'un cône avec un plan
- ▶ Équation pour un point $\mathbf{p} = (x, y)^T$: $ax^2 + bxy + cy^2 + dx + ey + f = 0$
- ▶ Sous forme matricielle :

$$\tilde{\mathbf{p}}^T \mathbf{C} \tilde{\mathbf{p}} = 0$$

$$\text{avec } \mathbf{C} = \begin{bmatrix} a & b/2 & d/2 \\ b/2 & c & e/2 \\ d/2 & e/2 & f \end{bmatrix}$$

- ▶ Défini à un facteur d'échelle prêt (donc 5 degrés de liberté)

- Soit une homographie H telle que $\tilde{p}' \propto H\tilde{p}$
- Pour un point p sur la conique C :

$$\begin{aligned}\tilde{p}^T C \tilde{p} &= 0 \\ \tilde{p}'^T (H^{-1})^T C H^{-1} \tilde{p}' &= 0 \\ \tilde{p}'^T H^{-T} C H^{-1} \tilde{p}' &= 0\end{aligned}$$

- Donc la conique C transformée par H devient $C' = H^{-T} C H^{-1}$.

- ▶ Conique Ω_∞ de points dans la plan à l'infini $\pi_\infty = (0, 0, 0, 1)^\top$
- ▶ Donc pour des points de la forme $(x, y, z, 0)^\top$, donc à l'infini
- ▶ Les points qui satisfont cette conique sont purement imaginaires (i.e il n'y a aucun point réel qui appartient à cette conique)

Ω_∞ est la conique de matrice : $C = I$ pour des points de la forme $(x, y, z)^\top$

- Projection des points de π_∞

$$p = KR[I|t] \begin{pmatrix} x \\ y \\ z \\ 0 \end{pmatrix} = KR \begin{pmatrix} x \\ y \\ z \end{pmatrix}$$

- seuls l'orientation de la caméra et ses paramètres internes influencent la projection de ces points

Analogie: La position du soleil ou des étoiles ne change pas si on se déplace, seulement si on change d'orientation.

Comme Ω_∞ est dans π_∞ on peut travailler avec les plans projectifs

- Posons $H = KR$
- Appliquons à $\Omega_\infty = I$

$$(KR)^{-\top} I (KR)^{-1} = K^{-\top} R I R^{-1} K^{-1} = K^{-\top} K^{-1}$$

Image de la Conique Absolue (*Image of the Absolute Conic (IAC)*)

$$\omega = K^{-\top} K^{-1}$$

Pour $\mathbf{K} = \begin{bmatrix} f & 0 & u \\ 0 & f\alpha & v \\ 0 & 0 & 1 \end{bmatrix}$

Au long,

$$\omega = \mathbf{K}^{-\top} \mathbf{K}^{-1} \propto \begin{bmatrix} \alpha^2 & 0 & -\alpha^2 u \\ 0 & 1 & -v \\ -\alpha^2 u & -v & f^2 \alpha^2 + u^2 \alpha^2 + v^2 \end{bmatrix}$$

Pour le moment, l'IAC est inconnue, nous allons l'estimer

$$\omega = \begin{bmatrix} w_1 & 0 & w_4 \\ 0 & w_2 & w_5 \\ w_4 & w_5 & w_3 \end{bmatrix}$$

Revenons à notre transformation \mathbf{H}

Rappel :

$$\mathbf{h}_1^\top \omega \mathbf{h}_2 = 0, \text{ et } \mathbf{h}_1^\top \omega \mathbf{h}_1 - \mathbf{h}_2^\top \omega \mathbf{h}_2 = 0$$

où \mathbf{h}_i est la $i^{\text{ème}}$ colonne de \mathbf{H}

Nous avons donc des contraintes linéaires:

$$\begin{bmatrix} g_1 g_2 & g_4 g_5 & g_7 g_8 & g_2 g_7 + g_1 g_8 & g_5 g_7 + g_4 g_8 \\ g_1^2 - g_2^2 & g_4^2 - g_5^2 & g_7^2 - g_8^2 & 2g_1 g_7 - 2g_2 g_8 & 2g_4 g_7 - 2g_5 g_8 \end{bmatrix} \begin{pmatrix} w_1 \\ w_2 \\ w_3 \\ w_4 \\ w_5 \end{pmatrix} = \mathbf{0}$$

avec

$$\mathbf{H} = \begin{bmatrix} g_1 & g_2 & g_3 \\ g_4 & g_5 & g_6 \\ g_7 & g_8 & g_9 \end{bmatrix}$$

Nous pouvons alors retrouver l'IAC et ensuite calculer les paramètres internes.

On peut maintenant retrouver les paramètres de \mathbf{K} .

Deux méthodes possibles:

- ▶ Calcul direct
- ▶ Décomposition de Cholesky

Exercice

- ▶ Combien faut-il d'homographie(s) pour calibrer complètement la caméra?
- ▶ Si le ratio d'image est 1 et qu'on connaît le point principal, combien en faut-il?

Pour une matrice symétrique définie positive $\mathbf{A}_{(n \times n)}$:

$$\mathbf{A} = \mathbf{L}_{(n \times n)} \mathbf{L}^{\top}$$

avec

- ▶ \mathbf{L} une matrice triangulaire inférieure
- ▶ une matrice est définie positive : $\forall \mathbf{x} \neq \mathbf{0}, \mathbf{x}^{\top} \mathbf{A} \mathbf{x} > 0$

Une fois \mathbf{K} connue...

Comment évaluer les paramètres externes (pose), \mathbf{R} et \mathbf{t} ?

Décomposer $\mathbf{N} \propto \mathbf{K}^{-1}\mathbf{H} = \mathbf{R} \begin{bmatrix} 1 & 0 \\ 0 & 1 & \mathbf{t} \\ 0 & 0 \end{bmatrix}$

- ▶ $\rho = 1/||\mathbf{n}_1|| = 1/||\mathbf{n}_2||$
- ▶ $\mathbf{r}_1 = \rho \mathbf{n}_1$
- ▶ $\mathbf{r}_2 = \rho \mathbf{n}_2$
- ▶ $\mathbf{r}_3 = \mathbf{r}_1 \times \mathbf{r}_2$
- ▶ $\mathbf{t} = \rho \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{r}_3 \end{bmatrix}^{-1} \mathbf{n}_3$

- ▶ Solution linéaire non optimale
- ▶ erreur algébrique vs erreur de reprojection
- ▶ Minimiser l'erreur de reprojection
- ▶ ATTENTION, ce n'est PAS de l'ajustement de faisceau (*Bundle Adjustment*)

Pour minimiser l'erreur géométrique, on va tomber dans l'optimisation non linéaire...

Pour toutes les vues i

$$\arg \min_{\mathbf{R}_i, \mathbf{c}_i, \mathbf{K}} \sum_{i,n} \text{dist}(\mathbf{p}_i, \mathbf{K} \mathbf{R}_i \begin{bmatrix} 1 & 0 \\ 0 & 1 & \mathbf{t}_i \\ 0 & 0 \end{bmatrix} \tilde{\mathbf{p}}_i)^2$$

- ▶ Plus difficile que pour les homographies
 - ▶ Contraintes sur \mathbf{R}

Première solution: Paramétrisation

- ▶ Euler : $\mathbf{R} = \mathbf{R}_x(r_x)\mathbf{R}_y(r_y)\mathbf{R}_z(r_z)$
- ▶ Fonctions compliquées
- ▶ Relativement difficile à optimiser
- ▶ Lent

Deuxième solution: Optimisation itérative (recommandée)

- ▶ À chaque étape de l'algorithme d'optimisation (e.g. Levenberg-Marquardt)
- ▶ Rotation par rapport à l'étape précédente est **semblable**
- ▶ Simplification de la fonction à chaque itération.
- ▶ Nous avons:

$$\mathbf{R}^{n+1} = \mathbf{R}' \mathbf{R}^n, \quad \text{ou} \quad \mathbf{R}' = \mathbf{R}_x(\phi) \mathbf{R}_y(\theta) \mathbf{R}_z(\rho)$$

- ▶ r_x, r_y, r_z sont **petits**
- ▶ Approximation de \mathbf{R}' :

$$\begin{aligned}\cos x &= 1 \\ \sin x &= x\end{aligned}$$

$$\mathbf{R}' \approx \begin{pmatrix} \theta\rho & -\theta & 1 \\ \rho + \phi & \rho\phi - 1 & -\theta \\ 1 - \rho\phi & \rho + \phi & \theta\phi \end{pmatrix}$$


Calibrage par Rotation pure

Définition

Caméra qui tourne parfaitement autour de son centre optique ($c = 0$)

R. I. Hartley. Self-calibration from multiple views with a rotating camera. In Proc. 3rd European Conf. on Computer Vision, Stockholm, volume 1, pages 471–478, 1994

- ▶ Aucun effet de profondeur
- ▶ Images de caméra reliée par des homographies



Deux caméras avec

- ▶ $H_1 = K$ (sans rotation, ni translation)
- ▶ $H_2 = KR$

Relier ensemble en faisant avec $\text{Image}_1 \xrightarrow{H_1^{-1}} \text{Monde} \xrightarrow{H_2} \text{Image}_2$:

$$H_{12} = KRK^{-1}$$

Rotation conjuguée

Une matrice $\mathbf{H} = \mathbf{URU}^{-1}$, où \mathbf{R} est une matrice orthogonale et \mathbf{U} est une transformation projective.

Pour une matrice de rotation \mathbf{R} , nous avons

- ▶ valeurs propres de la forme $\lambda(1, e^{i\theta}, e^{-i\theta})$,
(une réelle et deux complexes conjuguées)
- ▶ vecteurs propres correspondants $(\mathbf{a}, \mathbf{i}, \mathbf{j})$

θ l'angle

\mathbf{a} axe de rotation de la matrice, (et \mathbf{i}, \mathbf{j} perpendiculaires à \mathbf{a})

Pour une rotation conjuguée, l'angle est préservé, et les vecteurs propres sont prémultipliés par \mathbf{U} .

Exemple simple: ratio d'image à 1, point principal connu et mis à l'origine

Supposons $\mathbf{K} = \begin{bmatrix} f & 0 & 0 \\ 0 & f & 0 \\ 0 & 0 & 1 \end{bmatrix}$. Dans ce cas $\mathbf{H} = \begin{bmatrix} r_1 & r_2 & fr_3 \\ r_4 & r_5 & fr_6 \\ \frac{r_7}{f} & \frac{r_8}{f} & r_9 \end{bmatrix}$

- ▶ \mathbf{H} : presque une matrice de rotation
- ▶ solutions analytiques pour f

$$h_1^2 + h_2^2 + h_3^2/f^2 = h_4^2 + h_5^2 + h_6^2/f^2$$

ou bien

$$h_1h_4 + h_2h_5 + \frac{h_3h_6}{f^2} = 0$$

Distortion radiale

Distortion radiale

On a supposé les images absentes de toute distortion géométrique



La distorsion radiale s'applique sur les points dans la caméra normalisée

$$\hat{\mathbf{p}} = \mathbf{K}^{-1}\tilde{\mathbf{p}} = (\hat{x}, \hat{y}, 1)^{\top}$$

Modèle :

$$\begin{pmatrix} x^* \\ y^* \end{pmatrix} = L(\hat{r}) \begin{pmatrix} \hat{x} \\ \hat{y} \end{pmatrix}$$

avec

- ▶ $\hat{r}^2 = (\hat{x}^2 + \hat{y}^2)$ et k_1, k_2 les coefficients de distorsion
- ▶ $L(\hat{r}) = (1 + k_1\hat{r}^2 + k_2\hat{r}^4)$

On peut ensuite calculer les coordonnées dans l'image :

$$\tilde{\mathbf{p}} = \mathbf{K}(x^*, y^*, 1)^{\top}$$

Type de distorsion



(a)



(b)



(c)

Figure: (a) Barrel (b) Pincushion (c) Fish-eye

Pour corriger la distorsion radiale, il faut inverser la fonction de distorsion

Avec $\mathbf{K} = \begin{bmatrix} f & 0 & cx \\ 0 & f & cy \\ 0 & 0 & 1 \end{bmatrix}$ et (cx, cy) le centre de distorsion :

- ▶ $x = fx^* + cx = fL(\hat{r})\hat{x} + cx$ et sa version corrigée $x_d = f\hat{x} + cx$
- ▶ il faut connaître les coefficients de distorsion
- ▶ il faut retrouver \hat{r} pour chaque point
- ▶ une solution : construire une table $L(\hat{r})$ et l'utiliser pour retrouver \hat{r} en fonction de $r^* = \sqrt{(x^*)^2 + (y^*)^2}$

On peut aussi voir le problème comme un problème d'inverse-mapping :

- ▶ on peut calculer \mathbf{p}_d à partir de \mathbf{p} en appliquant la formule
- ▶ on trouve l'image dé-distorsionnée en allant de l'image corrigée vers l'image distorsionnée

Une méthode :

- ▶ Supposez le centre de distorsion au centre de l'image, et la calibration "connue" (ou proche)
- ▶ Itérez jusqu'à ce que le modèle minimise l'erreur algébrique par exemple :
 - ➊ Initialisez k_1 et k_2
 - ➋ Calculez \hat{x} et \hat{y}
 - ➌ Posez un système $Ax = b$ avec $x = (k_1, k_2)^T$ en utilisant le modèle plus haut
 - ➍ Résoudre avec la pseudo-inverse (ou SVD)
 - ➎ Recommencez en 2) jusqu'à convergence
- ▶ Éventuellement, réestimez les paramètres internes et la distorsion radiale avec une méthode non-linéaire

- ▶ La méthode standard est plutôt d'utiliser une minimisation non linéaire de la distance géométrique entre des correspondances (e.g points 3D-2D comme dans DLT), en incluant tous les paramètres
- ▶ L'ajustement de faisceaux permet (entre autres) de retrouver les paramètres internes de \mathbf{K} , la distorsion radiale, la pose et la meilleure position des points 3D qui minimise la distance géométrique
- ▶ Ces méthodes (non linéaires) donnent souvent de meilleurs résultats :
 - ▶ minimisent l'erreur géométrique
 - ▶ doivent être bien paramétrisées
 - ▶ exigent un bon estimé d'une solution de départ